

Lenart Miklavič

PROJEKTNA NALOGA IZ STATISTIKE

UL FMF, Matematika — univerzitetni študij

2025/26

Pred vami je projektna naloga iz statistike, ki je sestavni del obveznosti pri tem predmetu. Predavatelj vam je na voljo, če potrebujete nasvet. Morda boste morali uporabiti kakšno različico statistične metode, ki je na predavanjih ali vajah nismo omenili. Lahko si pomagata z učbenikom:

John Rice: *Mathematical Statistics & Data Analysis*, Duxbury, 2007,

ali katero drugo knjigo. V primeru težav z dostopom do učbenika se oglasite pri predavatelju.

Rešeno nalogo prosim oddajte v ustrezno rubriko na Učilnici v formatu ZIP. Tam naj bo zapakirana datoteka z imenom **Projektna_naloga.pdf**, v mapi **Priloge** pa naj bodo pomožne datoteke, npr. programi, s katerimi ste dobili rezultate. Toda v glavni datoteki morajo biti **sproti** vključeni vsi rezultati in grafikoni, poleg tega pa **na konec** (ponovno) dodajte še izpis kode vaših programov. Lažje je namreč, če je vse na enem mestu, pomožne datoteke pa pridejo prav, če jih je treba modificirati in (ponovno) zagnati. Datoteke z besedili nalog ne oddajajte.

Če stopnja tveganja pri preizkusu ni navedena, morate preizkusiti tako pri $\alpha = 0.01$ kot tudi pri $\alpha = 0.05$.

Rok oddaje je **ponedeljek, 7. september 2026**. Veliko uspeha pri reševanju!

NEKAJ NAPOTKOV ZA STAVLJENJE V T_EX-u oz. L^AT_EX-u

- Spremenljivke se dosledno stavijo ležeče, v T_EX-u torej med dolarji. Tako morate staviti, tudi če formula vsebuje en sam znak. Torej: slučajna spremenljivka X , ne slučajna spremenljivka X .
- Operatorji se stavijo pokončno, kar pa ne pomeni, da jih v T_EX-u postavimo kar izven dolarjev. Za najpogostejše operatorje so že naprogramirani ukazi. Torej $\mathrm{var}(X)$, ne $var(X)$.
- Če operator še ni definiran, ga sicer lahko stavimo recimo kot $\mathop{\mathrm{var}}$ (ukaz `\mathop` je pomemben zaradi presledkov), a bistveno lažje je, če definiramo ukaz, recimo v preambuli:

```
\usepackage{amsmath}
\DeclareMathOperator{\var}{var}
```

- Levo in desno od formule v besedilu mora biti vedno beseda ali pa ločilo. Med drugim se torej povedi na začenja s formulo. Narobe je torej recimo: “ X ima pričakovano vrednost 0, saj ima po trditvi 1 Y in z njim X simetrično porazdelitev.” Pravilno: “Slučajna spremenljivka X ima pričakovano vrednost 0, saj ima Y in z njim X po trditvi 1 simetrično porazdelitev.”
- Dele formul je dostikrat smiselno ločiti z dodatnimi presledki. Temu so namenjeni ukazi `\,`, `\,`, `\;`, `\>`, `\quad` in `\qquad`. Med drugim to storite tudi, kadar je faktor v produktu ulomek. Primer:

$$\frac{1}{\sqrt{2\pi}} e^{-z^2/2},$$

kar je bilo stavljeno kot `\[ \frac{1}{\sqrt{2 \pi}} \, , \, e^{- z^2/2} \]`.

- Za pogojevanje priporočam ukaz `\mid`, ki okoli navpičnice naredi ustrezen presledek. Če mora biti navpičnica višja, priporočam `\bigm|`, `\Bigm|` itd.
- Če pika ne označuje konca povedi, ji mora slediti ubežni ali pa trdi presledek, da T_EX ne naredi prevelikega presledka. Stavite torej npr.
Smolčki, tj. \ ljudje, rojeni 29.~februarja, naj bi rojstni dan praznovali le vsaka štiri leta.
- Za tri pike (...) uporabljamo ukaz `\ldots`. Toda paketa `xelatex` in `lualatex` te tri pike, kadar so v besedilu (ne v formuli), naredita zelo stisnjene (...). Če želimo tri pike vselej staviti narazen, lahko ukažemo
`\renewcommand{\textellipsis}{$ \mathellipsis $}` ali
`\renewcommand{\textellipsis}{%`
`.\kern\fontdimen3\font`
`.\kern\fontdimen3\font`
`.\kern\fontdimen3\font`
`}`

- Če poved zaključimo s tremi pikami, ne naredimo dodatne pike (tudi če so tiste tri pike del formule). Pač pa z ukazom `\spacefactor=3000{}` T_EX-u povemo, naj naredi presledek, primeren za zaključek povedi.
- Če boste decimalno vejico stavili kot običajno vejico, recimo 23,6, vam bo T_EX naredil presledek, torej 23,6, ker bo mislil, da gre za naštevanje. Rešitev: `23{,}6`.
- Formule, ki so predolge za eno vrstico, je treba razlomiti. Najpogosteje se to naredi z uporabo okolij `array`, `align`, `align*`, `gather`, `gather*` in `split` (slednje znotraj okolja `equation` ali `equation*`). Za vse razen prvega potrebujemo knjižnico `amsmath`.
- Za opombe, trditve, izreke, leme, dokaze in podobno priporočam okolje `amsthm`.
- Za spletne povezave priporočam ukaza `\url` in `\href` iz knjižnice `hyperref`.
- Grafikone postavite **natančno** na mesto, kamor sodijo. Za to recimo v okolju `figure` uporabite določilo H (ne h), pri tem pa je treba v preambulo dati `\usepackage{float}`.

1. V datoteki **Kibergrad** se nahajajo informacije o 43.886 družinah, ki stanujejo v mestu *Kibergrad*. Za vsako družino so zabeleženi naslednji podatki (ne boste potrebovali vseh):

- Tip družine (od 1 do 3)
 - Število članov družine
 - Število otrok v družini
 - Skupni dohodek družine
 - Mestna četrt, v kateri stanuje družina (od 1 do 4)
 - Stopnja izobrazbe vodje gospodinjstva (od 31 do 46)
- (a) Vzemite enostavni slučajni vzorec 200 družin in na njegovi podlagi ocenite povprečno število otrok na družino v Kibergradu.
- (b) Ocenite standardno napako in postavite 95% interval zaupanja.
- (c) Vzorčno povprečje in ocenjeno standardno napako primerjajte s populacijskim povprečjem in pravo standardno napako. Ali interval zaupanja iz prejšnje točke pokrije populacijsko povprečje?
- (d) Vzemite še 99 enostavnih slučajnih vzorcev in prav tako za vsakega določite 95% interval zaupanja. Narišite intervale zaupanja, ki pripadajo tem 100 vzorcem. Koliko jih pokrije populacijsko povprečje?
- (e) Izračunajte standardni odklon vzorčnih povprečij za 100 prej dobljenih vzorcev. Primerjajte s pravo standardno napako za vzorec velikosti 200.
- (f) Izvedite prejšnji dve točki še na 100 vzorcih po 800 družin. Primerjajte in razložite razlike s teorijo vzorčenja.

2. V datoteki **Mangan** so podatki o deležu mangana v železu, pridobljenem v plavžu: skozi 24 dni so vsak dan analizirali pet odlitkov. Preučite normalnost dobljene empirične porazdelitve, tako da narišete:

- histogram z dorisano ustrezno normalno gostoto;
- viseči histogram razlik korenov frekvenc: glejte razdelek 9.7 v knjigi;
- primerjalni kvantilni (Q–Q) grafikon: glejte razdelek 9.8 v knjigi.

Pri histogramu z dorisano normalno gostoto (ne pa tudi pri visečem histogramu) združite deleže mangana v razrede. Širino posameznega razreda določite v skladu z modificiranim Freedman–Diaconisovim pravilom.

Pri visečih histogramih premislite naslednje:

- Približno kakšno porazdelitev imajo frekvence, če so razredi fiksni, podatki neodvisne in enako porazdeljene slučajne spremenljivke, pričakovane frekvence dovolj velike, razredi pa vendar še dovolj ozki?
- Približno kakšno porazdelitev imajo kvadratni koreni teh frekvenc? Pri tem korensko funkcijo v glavnini dogajanja aproksimirajte z ustrezno linearno funkcijo. Utemeljite, da je napaka, ki jo naredimo, majhna v primerjavi z variacijo funkcije v glavnini dogajanja.

- Kako torej interpretiramo odstopanja v visečem histogramu?

Vir podatkov: I. Burr: *Applied Statistical Methods*. Academic Press, New York, 1974.

3. V neki raziskavi:

<http://www.statsci.org/data/oz/ms212.html>

so študentom merili pulz. Vsakemu študentu so pulz izmerili dvakrat. Določeni so imeli med obema meritvama fizično obremenitev (tek na mestu), določeni ne. Podatki so zbrani v tabeli **Pulz**, pri čemer imajo stolpci naslednje pomene:

VISINA	telesna višina
TEZA	telesna teža
STAROST	starost v letih
SPOL	1=moški, 2=ženski
KADI	1=kadilec, 2=nekadilec
ALKOHOL	1=pije, 2=ne pije
VADBA	1=vadi veliko, 2=vadi zmerno, 3=vadi malo ali pa sploh ne
OBREMENITEV	1=obremenitev, 2=brez obremenitve
PULZ1	prva meritev pulza
PULZ2	druga meritev pulza
LETO	leto meritve (1993–1998)

- (a) Raziščite, katere od dejavnikov višina, teža, spol in vadba je smiselno vključiti v linearni model, ki bo opisoval odvisnost prve meritve pulza od teh dejavnikov: poiščite model z najmanjšo *Akaikejevo informacijo*. Slednja nam pomaga izbrati le bistvene dejavnike. Akaikejeva informacija je sicer definirana z verjetjem, a pri linearni regresiji in Gaussovem modelu je le-ta ekvivalentna naslednji modifikaciji:

$$AIC := 2p + n \ln RSS,$$

kjer je p število parametrov, n pa je število opazanj.

- (b) Za vsakega od dejavnikov kajenje in alkohol vaš model preizkusite proti širšemu modelu, ki poleg dejavnikov, izbranih v prejšnji točki, vključi tudi še dodatni dejavnik.